

Գծային ռեգրեսիա

Հայկ Կարապետյան

1 Նկարագրություն

Ունենք բնակարանների տվյալների զույգեր $(x_i, y_i)_{i=1}^n$, $x_i \in R^k$, $y_i \in R$: x -ը ներկայացնում է բնակարանի k հատ բնութագրիչները (x_i^1 - սենյակների քանակ, x_i^2 - մակերես, x_i^k - k -րդ բնութագրիչ), իսկ y -ը բնակարանի գինն է: Սահմանենք հետևյալ ֆունկցիան.

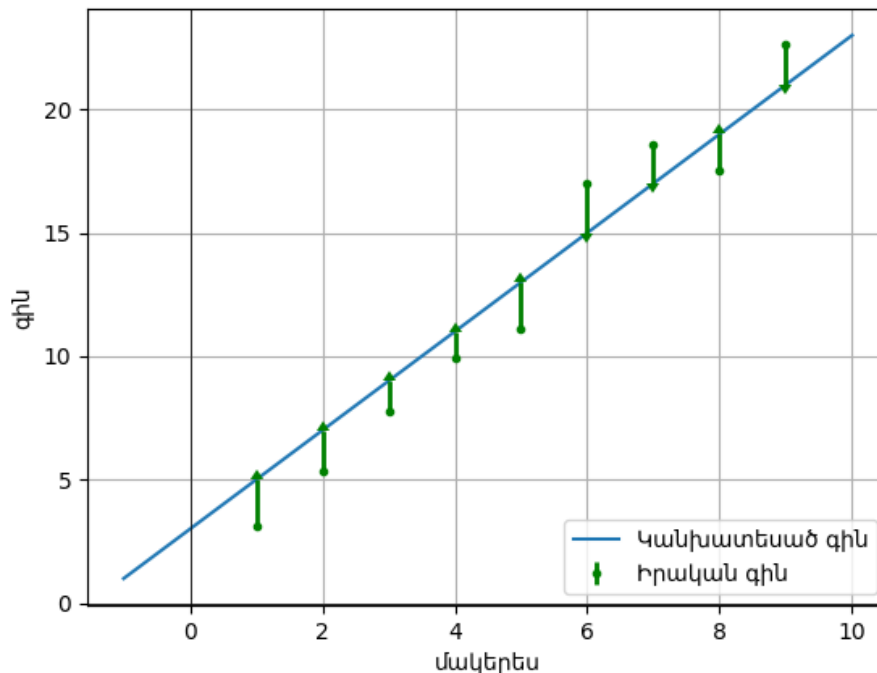
$$f(x) = f(x^1, x^2, \dots, x^k) = w^1 x^1 + w^2 x^2 + \dots + w^k x^k + b = w^T x + b$$

$$x = \begin{bmatrix} x^1 \\ x^2 \\ \dots \\ x^k \end{bmatrix}, \quad w = \begin{bmatrix} w^1 \\ w^2 \\ \dots \\ w^k \end{bmatrix}$$

Մեր նպատակն է գտնել այնպիսի w^1, w^2, \dots, w^k, b պարամետրեր, որ $f(x_i) \approx y_i, i = 1, \dots, n$ և ոչ միայն մեր ունեցած տվյալների համար: Հետևյալ ֆունկցիայի (զծի) պարամետրերը գտնելը կոչվում է գծային ռեգրեսիա (linear regression): Սահմանենք L^2 հեռավորությունը որպես կորստի ֆունկցիա:

$$L = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$$

Հետևյալ կորստի ֆունկցիան միմիմիզացնելը կնշանակի, որ մենք հասել ենք մեր նպատակին:



Նկար 1: Կանաչ գծեր ցույց է տալիս կորուստը և մոդելի ուսուցումից հետո հեռավորությունը կանխատեսած ու իրական գնի միջև պետք է լինի նվազագույնը:

Կորուստը նվազագույնի հասցնելու և պարամետրերի արժեքները գտնելու համար ունենք 2 եղանակ.

1. Ածանցյալը հավասարեցնենք զրոյի
2. Օգտագործենք գրադիենտային վայրեջրի մեթոդը

Մեթոդ 1. Վերցնենք $f(x) = X\theta$, $L(\theta) = \frac{1}{n}(X\theta - y)^2$:

$$X = \begin{bmatrix} x_1^1, x_1^2, \dots, x_1^k, 1 \\ x_2^1, x_2^2, \dots, x_2^k, 1 \\ \dots \\ x_n^1, x_n^2, \dots, x_n^k, 1 \end{bmatrix}, \quad \theta = \begin{bmatrix} w^1 \\ w^2 \\ \dots \\ w^k \\ b \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}$$

Լուծումը տեսնելու համար կարող եք միանգամից անցնել (1) հավասարմանը

$$J(\theta) = \frac{\partial L(\theta)}{\partial \theta} = \frac{1}{n}(X\theta - y)^T(X\theta - y)$$

$\frac{1}{n}$ հաստատուն է և փոփոխում է միայն մինիմումի արժեքը, ոչ թե կետը

$$J(\theta) = ((X\theta)^T - y^T)(X\theta - y)$$

$$J(\theta) = (X\theta)^T(X\theta) - (X\theta)^T y - y^T(X\theta) + y^T y$$

$$\text{Հաշվի առնելով որ } ((X\theta)^T y)^T = y^T(X\theta)$$

$$J(\theta) = (X\theta)^T(X\theta) - 2y^T(X\theta) + y^T y$$

$$J(\theta) = \theta^T X^T X \theta - 2y^T X \theta + y^T y$$

Հայտնի մատրիցային ածանցյալների բանաձևերն են.

$$\frac{\partial (AX)}{\partial X} = A^T$$

$$\frac{\partial (X^T A)}{\partial X} = A$$

$$\frac{\partial (X^T X)}{\partial X} = 2X$$

$$\frac{\partial (X^T A X)}{\partial X} = AX + A^T X$$

$$\frac{\partial J(\theta)}{\partial \theta} = X^T X \theta + X^T X \theta - 2X^T y = 2X^T X \theta - 2X^T y$$

Գտնելու համար θ -ն, ածանցյալը հավասարեցնենք զրոյի:

$$2X^T X \theta - 2X^T y = 0$$

$$X^T X \theta = X^T y$$

$$\theta = (X^T X)^{-1} X^T y \quad (1)$$

Հետագայում նոր բնակարանի k հատ բնութագրիչ ունենալու դեպքում, կբազմապատկենք θ -ով և կգուշակենք գինը:

Մերթող 2. Վերցնենք $f(x) = XW + b$, $L(W, b) = \frac{1}{n}(XW + b - y)^2$, $\alpha = 0.1$:

$$X = \begin{bmatrix} x_1^1, x_1^2, \dots, x_1^k \\ x_2^1, x_2^2, \dots, x_2^k \\ \dots \\ x_n^1, x_n^2, \dots, x_n^k \end{bmatrix}, \quad W = \begin{bmatrix} w^1 \\ w^2 \\ \dots \\ w^k \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}$$

$$\nabla L = \left[\frac{\partial L}{\partial W}, \frac{\partial L}{\partial b} \right] = \left[\frac{2X}{n}(XW + b - y), \frac{2}{n}(XW + b - y) \right]$$

Ամեն գրադիենտային վայրենջրի քայլի ընթացքում թարմացնելու ենք կշիռները հետևյալ կերպ.

$$W = W - \alpha \frac{\partial L}{\partial W}$$

$$b = b - \alpha \frac{\partial L}{\partial b}$$

Իսկ ինչպե՞ս կարող ենք ներկայացնել ռեգրեսիան, որպես նեյրոնային ցանց: Ամեն ինչ պարզ է՝ մեկ նեյրոն և ոչ մի ակտիվացիոն ֆունկցիա:

2 Քառակուսային կորուստը ընդդեմ մոդուլով կորստի

Իսկ ինչու ենք օգտագործում քառակուսային կորստի ֆունկցիան, մոդուլի փոխարեն.

$$MSE(Squared) = (f(x) - y)^2 \quad vs \quad MAE(Absolute) = |f(x) - y|$$

$$f(x) = wx + b$$

$$\frac{\partial MSE}{\partial w} = 2(f(x) - y) \times \frac{\partial f(x)}{\partial w} \quad vs \quad \frac{\partial MAE}{\partial w} = \text{signum}(f(x) - y) \times \frac{\partial f(x)}{\partial w}$$

Կարող ենք տեսնել, որ MSE կորստի ֆունկցիայի դեպքում ինչքան մոտիկանում ենք y-ին, այնքան մասնակի ածանցյալը փոքրանում է, այսինքն ավելի փոքր քայլերով ենք շարժվում, իսկ MAE-ի դեպքում, անկախ նրանից, թե ինչքան մոտ ենք y-ին, նույն չափով շարժվում ենք դրական կամ բացասական ուղղությամբ՝ կախված signum-ի նշանից: Ավելի փոքր քայլերով շարժվելը նշանակում է, որ մինչ կշիռի թարմացումը և թարմացումից հետո ստացված կշիռի արժեքների տարբերությունը մեծ չի: Որոշ դեպքերում օգտագործելով MAE կորուստը և ավտոմատ կերպով ուսուցման արագության (learning rate) փոքրացումը կարող են տալ նույն արդյունքը, ինչ MSE կորուստով ուսուցումը: