

# L1 և L2 Ռեգուլարիզացիաներ

## Հայկ Կարապետյան

Ռեգուլարիզացիան գերուսուցումից խուսափելու մեթոդը: Ծանոթանանք, թե ինչպես է դա հնարավոր: Ունենք տան գնի գուշակման խնդիր: Սահմանենք ներդրոնային ցանց բաղկացած մեկ շերտից և  $k$  հատ ներդրոնից: Պատկերացնենք ֆունկցիաների բազմություն (A), որոնք ստացվել  $f(x) = wx + b$  ֆունկցիայի մեջ տարբեր  $w$  և  $b$  արժեքներ տեղադրելիս:

$$A = \{wx + b, w \in R^k, b \in R\}$$

Գերուսուցված ֆունկցիան և լավագույն ֆունկցիան, որը կարողանում է լուծել տան գնի գուշակման խնդիրը 100% ճշգրտությամբ, նույնպես գտնվում են այդ բազմության մեջ: Մոդելը ուսուցանելիս մենք ձգտում ենք գտնել այդ լավագույն ֆունկցիան, բայց կարող ենք հասնել գերուսուցված ֆունկցիան: Այդ պատճառով եկեք փոքրացնենք մեր բազմությունը: Եկեք սահմանափակենք  $w$ -ի փոփոխման տիրույթը: Օրինակ՝  $w$ -ն ձգտեցնենք գրոյի: Դա հնարավոր է կազմակերպել օգտագործելով կորստի ֆունկցիան: Այսինքն մեզ պետք է կատարել այնպիսի ձևափոխություն կորստի ֆունկցիայի մեջ, որ  $w$ -ն ձգտի 0-ի:

$$L = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$$
$$L_{L1} = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2 + \frac{\lambda}{k} \sum_{i=1}^k |w_i|$$
$$L_{L2} = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2 + \frac{\lambda}{k} \sum_{i=1}^k w_i^2$$

Այստեղ  $\lambda$ -ն հիպերպարամետր է, որը ցույց է տալիս, թե մեզ համար ինչքան կարևոր է կշիռների փոքր լինելը,  $k$ -ն շերտում ներդրոնների քանակը:  $\lambda$ -ի արժեքը փոփոխվում է (0; 1) միջակայքում, քանի որ  $f(x) \approx y$  ավելի կարևոր է, քան կշիռների փոքր լինելը: Կշիռները փոքր լինելու միջոցով, մոդելի գերուսուցումից խուսափելու մեթոդը կոչվում է ռեգուլարիզացիա (regualrization): Երկու տեսակի ռեգուլարիզացիաներն էլ ապահովում են կշիռների փոքր լինելը, բայց նրանց մեջ կա տարբերություն: Դիտարկենք այդ տարբերությունը կշիռների թարմացման ժամանակ:

### L1 Regularization

$$w_1 = w_1 - \alpha \times \left( \nabla L + \frac{\partial \frac{\lambda}{k} \sum_{i=1}^k |w_i|}{\partial w_1} \right)$$

$$w_1 = w_1 - \alpha \times \frac{w_1}{|w_1|} - \alpha \nabla L$$

$$w_1 = w_1 - \alpha \times \text{signum}(w_1) - \alpha \nabla L$$

Ամեն անգամ  $w_1$ -ին գումարում ենք կամ հանում ենք  $\alpha$   
Եվ դրա շնորհիվ հնարավոր է  $w_1$ -ի արժեքը հասցնել 0-ի

### L2 Regularization

$$w_1 = w_1 - \alpha \times \left( \nabla L + \frac{\partial \frac{\lambda}{k} \sum_{i=1}^k w_i^2}{\partial w_1} \right)$$

$$w_1 = w_1 - \alpha \times 2w_1 - \alpha \nabla L$$

$$w_1 = w_1(1 - 2\alpha) - \alpha \nabla L$$

$w_1$ -ից ամեն անգամ դեն ենք նետում իր  $(1 - 2\alpha)$  մասը և այն 0 չի դառնա

L1 ռեգուլարիզացիան հայտնի է նաև Lasso regression անվանումով, իսկ L2 ռեգուլարիզացիան Ridge regression անվանումով: Ինչպես նշեցինք, երկուսն էլ գերուսուցումից խուսափելու մեթոդներ են, բայց դա չի նշանակում, որ դրանք օգտագործելիս մոդելը չի կարող գերուսուցվել:

L1 ռեգուլարիզացիան նաև օգտագործվում է անպետք հատկանիշներ (features) գտնելու համար: Օրինակ՝ տան գների գուշակման խնդրում կատարել ենք ռեգրեսիա՝ L1 ռեգուլարիզացիայով: Ուսուցումից հետո մոդելի կշիռները տպելիս հնարավոր է, որ մի քանիսը շատ մոտ լինեն 0-ի: Դա նշանակում է, որ տվյալ հատկանիշի արժեքը չի ազդում տան գնի վրա (տան տիրոջ անուն):