

# Փաթույթ

## Հայկ Կարապետյան

### 1 Անհրաժեշտություն

Ունենք  $(200, 200, 3)$  չափ ունեցող նկար: Հաշվենք հետևյալ նկարը մեր սովորական dense neural network-ին մուտքում տալիս, քանի կշիռ է հարկավոր: Սահմանենք մեր ցանցը կազմված մի շերտից և այդ շերտում կա 100 նեյրոն: Որպեսզի մենք մուտքում տանք նկարը, մեզ հարկավոր է այն դարձնել միաչափ և այդ դեպքում մուտքային արժեքների քանակարը հավասար կլինի  $200 \times 200 \times 3 = 120000$ : Անհրաժեշտ կշիռների քանակը հավասար կլինի  $120000 \times 100 + 100 = 12000100$ : Այսինքն միայն առաջին շերտում ստացանք 12 միլիոն պարամետր, որը բավականին շատ է: Սա առաջին խնդիրն է: Երկրորդ խնդիրն այն է, որ մենք ցանկանում ենք պահպանել նկարի խորությունը, հարթացնելու (flatten) փոխարեն, քանի որ մարդն էլ նկարին նայելիս ուղղակի չի տեսնում այդ թվերը, այլ հաշվի է առնում նկարի եռաչափ (3 channel) լինելը: Հետևյալ երկու խնդիրներից բխում է փաթույթային (convolutional) ցանցերի անհրաժեշտությունը:

### 2 Մաթեմատիկական բանաձև

Convolution-ը գալիս է մաթեմատիկայից: Դիտարկենք հետևյալ բանաձևերը:

#### 1. 1D Convolution

##### (a) անընդհատ դեպք

Ունենք երկու ֆունկցիա՝  $f, g : \mathbb{R} \rightarrow \mathbb{R}$ :  $f$  ֆունկցիայի վրա փաթաթել  $g$  ֆունկցիան սահմանվում է. երկու ֆունկցիաների արտադրյալի ինտեգրալը, երբ ֆունկցիաներից մեկը հայելային շրջվում է և տեղափոխվում: Բանաձևը կլինի հետևյալը.

$$(f * g)(t) =: \int_{-\infty}^{+\infty} f(x)g(t-x)dx$$
$$g(x) \rightarrow g(-x) \rightarrow g(t-x)$$

$g(x)$  ֆունկցիան հայելային շրջում ենք  $x$  առանցքի նկատմամբ և ստանում ենք  $g(-x)$ , ապա տեղափոխում ենք  $x$  առանցքի ուղղությամբ  $t$ -ով՝  $g(t-x)$ : Եկեք տեսնենք, որ  $f * g = g * f$

$$(f * g)(t) =: \int_{-\infty}^{+\infty} f(x)g(t-x)dx$$
$$t-x =: k$$
$$\int_{-\infty}^{+\infty} f(t-k)g(k)d(t-k) = \int_{+\infty}^{-\infty} -f(t-k)g(k)dk = \int_{-\infty}^{+\infty} f(t-k)g(k)dk = (g * f)(k)$$

##### (b) դիսկրետ դեպք

Ունենք իրական թվերից բաղկացած երկու հաջորդականություն՝  $\{f_n\}_{n=-\infty}^{+\infty}, \{g_n\}_{n=-\infty}^{+\infty}$ : Հետևյալ հաջորդականությունների փաթաթումը  $n$  կետում գրենք հետևյալ կերպ.

$$z_n =: \sum_{k=-\infty}^{+\infty} f_k g_{n-k}$$

#### 2. 2D Convolution

##### (a) անընդհատ դեպք

Սահմանենք  $f, g : \mathbb{R}^2 \rightarrow \mathbb{R}$ .

$$(f * g)(t, \tau) =: \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y)g(t-x, \tau-y)dx dy$$

Այստեղ նույնպես նույն կերպ կարող ենք տեսնել որ  $f * g = g * f$

(b) դիսկրետ դեպք

Վերցնենք  $f(x)$  ֆունկցիան և դա թող լինի մեր նկարը (այս ֆունկցիան վերադարձնելու է տվյալ կոորդինատի պիքսելի արժեքը) ու վերցնենք  $w(s, t)$  միջուկը (kernel), որը փաթաթելու ենք մեր նկարի վրա:  $s \in [-a, a]$ ,  $t \in [-b, b]$ ,  $(x, y, s, t, a, b) \in \mathbb{Z}$

$$(f * w)(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b f(x, y)w(x - s, y - t)$$

Այս դեպքում մեր  $f$  նկարը ֆիքսում ենք և  $w$  միջուկը շարժում ենք նկարի վրայով:

### 3 Կիրառում ցանցերում

Հիմա նայենք, թեգործնականում փաթույթը, ինչպես է կիրառվում նկարի վրա: Ունենք.

$$f = \begin{bmatrix} f_{11} & f_{12} & f_{13} \\ f_{21} & f_{22} & f_{23} \\ f_{31} & f_{32} & f_{33} \end{bmatrix}, w = \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{bmatrix}, f * w = \begin{bmatrix} k_{11} & k_{12} \\ k_{21} & k_{22} \end{bmatrix}$$

$k_{11}$ -ը ստանալու համար  $w$  միջուկը տեղադրում ենք նկարի վրա և ամեն իրար վրա ընկած անդամ բազմապատկում ենք իրարով: Վերջում բոլորը գումարում ենք իրար:

$$k_{11} = w_{11} \times f_{11} + w_{12} \times f_{12} + w_{21} \times f_{21} + w_{22} \times f_{22}$$

$k_{12}$ -ը ստանալու համար միջուկը մեկ քայլ տեղափոխում ենք աջ և կատարում փաթույթի գործողությունը:

$$k_{12} = w_{11} \times f_{12} + w_{12} \times f_{13} + w_{21} \times f_{22} + w_{22} \times f_{23}$$


$k_{21}$ -ը ստանալու համար միջուկը տեղափոխում ենք տողի սկիզբը, մեկ քայլ տեղափոխում ենք ներքև և կատարում փաթույթի գործողությունը:

$$k_{21} = w_{11} \times f_{21} + w_{12} \times f_{22} + w_{21} \times f_{31} + w_{22} \times f_{32}$$

$k_{22}$ -ը ստանալու համար միջուկը մեկ քայլ տեղափոխում ենք աջ և կատարում փաթույթի գործողությունը:

$$k_{22} = w_{11} \times f_{22} + w_{12} \times f_{23} + w_{21} \times f_{32} + w_{22} \times f_{33}$$

Մեկ փաթույթի քայլ պատկերված է նկար 1-ում: Հիմա նայենք, թե ինչպես ենք կիրառելու



Նկար 1: convolution քայլ

$$result_{11} = -4 + 0 + 0 + 0 + 1 + 0 + 0 + 0 + 2 = -1$$

convolution գունավոր (RGB) նկարների դեպքում: RGB նկարը gray դարձնելու համար մենք ամեն channel բազմապատկում ենք ինչ որ գործակցով և վերջում ստանում ենք մի նկար:

$$gray = \alpha_1 R + \alpha_2 G + \alpha_3 B, \alpha_1 + \alpha_2 + \alpha_3 = 1$$

6x6x3 նկարի վրա ուզում ենք կիրառել 3x3 չափանի միջուկով փաթույթ: 3x3 չափանի միջուկը մեզ բավարար չէ, մեզ հարկավոր է ևս մի խորություն և միջուկի չափը կդառնա 3x3x3:

$$Image = \begin{bmatrix} R \\ G \\ B \end{bmatrix}, R = \begin{bmatrix} r_{11} & \dots & r_{16} \\ \vdots & & \vdots \\ r_{61} & \dots & r_{66} \end{bmatrix}, G = \begin{bmatrix} g_{11} & \dots & g_{16} \\ \vdots & & \vdots \\ g_{61} & \dots & g_{66} \end{bmatrix}, B = \begin{bmatrix} b_{11} & \dots & b_{16} \\ \vdots & & \vdots \\ b_{61} & \dots & b_{66} \end{bmatrix}$$

$$W = \begin{bmatrix} W_1 \\ W_2 \\ W_3 \end{bmatrix}, W_1 = \begin{bmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{bmatrix}, W_2 = \begin{bmatrix} w'_{11} & w'_{12} & w'_{13} \\ w'_{21} & w'_{22} & w'_{23} \\ w'_{31} & w'_{32} & w'_{33} \end{bmatrix}, W_3 = \begin{bmatrix} w''_{11} & w''_{12} & w''_{13} \\ w''_{21} & w''_{22} & w''_{23} \\ w''_{31} & w''_{32} & w''_{33} \end{bmatrix}$$

$$Image * W = R * W_1 + G * W_2 + B * W_3 = \begin{bmatrix} k_{11} & \dots & k_{14} \\ \vdots & & \vdots \\ k_{41} & \dots & k_{44} \end{bmatrix}$$

Տեսնենք թե ինչ է կատարվում առաջին քայլում

$$k_{11} = c_{11} + c_{12} + c_{13} + \dots + c_{31} + c_{32} + c_{33}$$


$$c_{ij} = w_{ij} \times r_{ij} + w'_{ij} \times g_{ij} + w''_{ij} \times b_{ij} \quad i = 1, 2, 3, j = 1, 2, 3$$

Առաջին քայլի ժամանակ տեսանք, որ երեք միջուկները տեղադրվում են 3 channel-ների վրա, բազմապատկում ենք իրար վրա ընկած արժեքները և գումարում ենք ըստ խորության: Իսկ ինչ կստացվի եթե ոչ թե ուղղակի գումարենք իրար ըստ խորության, այլ բազմապատկենք ինչ որ գործակցով, հետո նոր գումարենք:

$$c_{ij} = \alpha_1 \times w_{ij} \times r_{ij} + \alpha_2 \times w'_{ij} \times g_{ij} + \alpha_3 \times w''_{ij} \times b_{ij} \quad i = 1, 2, 3, j = 1, 2, 3$$

$w_{ij}$  արժեքը ուսուցանվող պարամետր է և այն կարող է սովորել  $\alpha \times w_{ij}$ -ի արժեքը, այդ պատճառով իմաստ չունի բազմապատկել ինչ որ գործակցով նոր գումարել:

Այսպիսով ստացանք, որ գունավոր 6x6x3 նկարի վրա 3x3x3 միջուկ կիրառելուց հետո ստանում ենք 4x4 նկար 2:



Նկար 2: Convolution RGB նկարի վրա

Իսկ ինչպե՞ս կարող ենք ստանալ 4x4x3 նկար: Դրա համար մեզ անհրաժեշտ է կիրառել 3x3x3x3 միջուկ և այդ բոլոր միջուկների կշիռները տարբեր են լինելու: Սրանից հետևում է, որ միջուկները ընդհանուր դեպքում կարող են ունենալ 4 խորություն:

1. նկարի երկարություն
2. նկարի բարձրություն
3. նկարի խորություն
4. արդյունքում ինչքան խորություն ենք ուզում ստանալ

Հիմնականում միջուկները լինում են կենտ չափերի քառակուսիներ: Կենտ չափը կապված է նրանով, որ այդ դեպքում այն ունի կենտրոն: Միջուկը նկարի վրա շարժելիս դիտարկում ենք ամեն պիքսելը, որպես կենտրոն և տեսնում ենք դրա շրջակայքում ինչ է կատարվում: Նկարի վրա 1x1 միջուկով փաթույթ կիրառելիս նկարի բոլոր պիքսելները կբազմապատկվեն մի թվով, դա նույնն է, որ մատրիցը բազմապատկենք թվով:

## 4 Padding

Հիմա դիտարկենք դեպք, երբ ցանկանում ենք նկարի չափը նույնը թողնել, բայց նկարի վրա կիրառել convolution. Սկզբնական նկարը 6x6 չափի է, դրա վրա 3x3 convolution կիրառելիս կստանանք 4x4: 6x6 նկարի բոլոր կողմերից ավելացնենք 0-ներ:


$$Image = \begin{bmatrix} x_{11} & \dots & x_{16} \\ \vdots & & \vdots \\ x_{61} & \dots & x_{66} \end{bmatrix}, \quad Image\_padded = \begin{bmatrix} 0 & 0 & \dots & 0 & 0 \\ 0 & x_{11} & \dots & x_{16} & 0 \\ \vdots & & \vdots & & \vdots \\ 0 & x_{61} & \dots & x_{66} & 0 \\ 0 & 0 & \dots & 0 & 0 \end{bmatrix}$$

Ստացված 8x8 նկարի վրա փաթույթ կիրառելիս կստանանք 6x6 նկար:

0-ներ նկարին ավելացնելու գործընթացը կոչվում է padding: Երբ padding=same, նշանակում է այնքան ենք ավելացնում 0-ներ, որ փաթույթ կիրառելուց հետո նկարը մնա նույն չափի, իսկ երբ padding=valid նշանակում է, որ մեզ հետաքրքիր չէ, թե նկարը ինչքան կփոքրանա մենք կիրառում ենք սովորական convolution: padding=2 նշանակում է նկարի բոլոր կողմերից ավելացնում ենք երկու սյուն կամ երկու տող 0-ներ: Padding կիրառելուց հետո նկարի եզրերը նույնպես դառնում են կենտրոններ միջուկի համար: Եթե ունենք 3x3 միջուկ և շարժում ենք սկզբնական նկարի վրայով, եզրերի արժեքները երբեք չեն գտնվի միջուկի կենտրոնում, իսկ padding-ից հետո այդպիսի խնդիր չի առաջանա և դիտարկելով եզրերի արժեքները, որպես կենտրոն կարող ենք ասել նրանց շրջակայքում ինչ է կատարվում: Այս ամենը շատ արստրակտ է և ապացուցված չէ, որ միջուկը կենտ չափի վերցնելիս առաջանում է կենտրոն և շրջակայք հասկացություններ:

## 5 Քայլով convolution

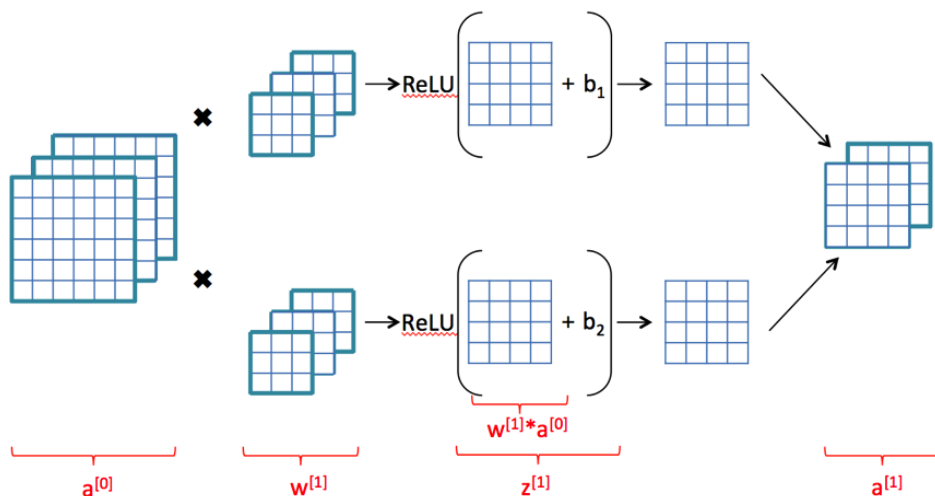
Վերը դիտարկված դեպքերում convolution-ի քայլը (stride) 1 է: Մենք դիտարկում ենք բոլոր պիքսելները (բացի եզրայիններից), որպես կենտրոն և նայում ենք դրանց շրջակայքում ինչ է կատարվում: Երբ վերցնենք և երկու քայլով շարժվենք, կդիտարկենք միայն կենտ տեղերում գտնվող պիքսելները (չհաշված եզրերը), որպես կենտրոն և կնայենք դրանց շրջակայքը (Նկար 3): Արդյունքում կստանանք ավելի փոքր նկար, քան մեկ քայլով փաթույթի դեպքում էր:



Նկար 3: 2 strided convolution

## 6 Մեկ շերտ convolution

Նկար 4-ում պատկերված է, թե ինչ տեսք ունի փաթույթի մեկ շերտը: Մեզ հարկավոր է ունենալ 3 խորություն ունեցող միջուկ, անցկացնել այդ միջուկը մեր նկարի վրայով ստանալ մեկ խորություն ունեցող մատրից, գումարել բիաս և կիրառել ակտիվացիոն ֆունկցիա: Արդյունքում ստացված մատրիցը անվանում են feature map: Այն կարող ենք տալել և կոտեսնենք, որ սկզբնական նկարն է, որոշ ձևափոխություններով: Օրինակ՝ եզրերը ընդգծված կամ շան պոչի մասը առանձնացված: Մեր 3 խորությամբ միջուկը նման է մեկ նեյրոնի և եթե ուզում ենք շերտում ունենալ մի քանի նեյրոն և համապատասխանաբար արդյունքում մի քանի feature map, մեզ պետք է մի քանի 3 խորությամբ միջուկներ կիրառել և ամեն մեկին առանձին գումարել բիաս, կիրառել ակտիվացիոն ֆունկցիա և ստացված feature map-երը միավորել իրար ըստ խորության:



Նկար 4: 1 շերտից բաղկացած convolution: Շերտում առկա է երկու նեյրոն

Մեկ նեյրոնից բաղկացած convolution կիրառելու դեպքում output feature map-ի չափը որոշվում է հետևյալ բանաձևով.

$$W_{new} = \frac{W - F + 2P}{S} + 1$$

$W_{new}$  – Նկարի նոր երկարություն

$W$  – Նկարի երկարություն

$F$  – Միջուկի (kernel կամ filter) երկարությունը (3x3՝ 3)

$P$  – Padding-ի չափը

$S$  – Քայլի չափը (stride)

Նույն կերպ կարող են որոշել ստացված feature map-ի բարձրությունը:

## 7 Կիրառությունն նկարներում

Ունենք նկար և մեզ պետք է նկարից առանձնացնել եզրագծերը: Եկեք ամեն սյունից հանենք իր նախորդ սյունը: Եթե սյունակների թվերը նույնը լինեն իրար կգրոյացնեն, հակառակ դեպքում կունենանք 0-ից մեծ թիվ և դա կնշանակի, որ եզրագիծ է: Օրինակ երկնից դեպի գետին սահմանը կունենա եզրագիծ: Ինչպե՞ս սա կարող ենք ներկայացնել convolution-ի տեսքով: Վերցնենք հետևյալ միջուկը.

$$w = \begin{bmatrix} -1 & 1 \\ 0 & 0 \end{bmatrix}$$

Հետևյալ միջուկով նկարի վրա անցնելիս ամեն սյան արժեքից կհանենք իր նախորդ սյան արժեքը: Ավելի լավ միջուկներին կարող եք ծանոթանալ հետևյալ կայքում:

## 8 Եզրակացություն

Սկզբնական խնդիրն այն էր, որ մենք սովորական dense շերտ օգտագործելու դեպքում ունենում էինք շատ ուսուցանվող պարամետրեր (12 միլիոն): Եկեք հաշվենք, թե ինչքան պարամետր ենք օգտագործում փաթույթային ցանցերում: Ուսուցանվող պարամետրերը միջուկների արժեքներն են: Այսինքն եթե ունենք 3x3 չափի միջուկ, ուսուցանվող պարամետրերի քանակը 9 է: Վերցնենք առաջին շերտում ունենք 3x3x3 չափանի 10 հատ միջուկ: Ընդհանուր ուսուցանվող պարամետրերի քանակը ստացվեց 270: Փաթույթային ցանցերը նման են մարդուն: Նկարի սկզբից միջուկը վազում է նկարի վրայով և փնտրում է իրեն անհրաժեշտ օբյեկտները: Օրինակ՝ նկարի վրա վազելիս ամեն հատվածի կարող է ասել այդ հատվածում շան ինչ որ մաս կա թե ոչ: Եթե ցանցը լրիվ փաթույթային է (fully convolutional), այսինքն ոչ մի dense շերտ առկա չէ, ցանցի մուտքային նկարը կարող է լինել տարբեր չափերի: Ի տարբերություն dense շերտի հնարավոր է ունենալ ոչ ֆիքսված չափի մուտք: